

## 机器学习数学：拉格朗日对偶问题



岭大王

啊，好热！

221 人赞同了该文章

对偶问题是利用拉格朗日对偶性将原始问题转换为对偶问题，通过解对偶问题得到原始问题的解。

优点是：

- 对偶问题往往更易于求解
- 自然引入核函数，推广到非线性分类问题的求解

### 原始问题

我们以硬间隔svm的原始问题为例，求解一个约束最优化问题：

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} |w|^2 \\ \text{s.t.} \quad & y_i(w x_i + b) - 1 \geq 0 \\ & i = 1, 2, \dots, N \end{aligned}$$

(注：这个问题用二次规划求解时复杂度与x的维度有关)

我们将这个问题一般化：

$$\begin{aligned} \min_{x \in R^n} \quad & f(x) \\ \text{s.t.} \quad & c_i(x) \leq 0 \quad i = 1, 2, \dots, k \\ & h_j(x) = 0 \quad j = 1, 2, \dots, l \end{aligned}$$

### 极小极大问题

引入拉格朗日函数，由于约束条件有k+l个，所以我们有：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

(求对x有限制条件的f(x)的最优化问题转为对  $x, \alpha, \beta$  没有限制条件的  $L(x, \alpha, \beta)$  极值问题)

其中  $\alpha_i, \beta_j$  是拉格朗日乘子， $\alpha_i \geq 0$ ，我们再定义一个函数：

$$\theta_p(x) = \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta)$$

(注：在  $\alpha, \beta, \alpha_i \geq 0$  条件下的最大值)

我们来研究这个函数：

$$\theta_p(x) = \max_{\alpha, \beta, \alpha_i \geq 0} (f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x))$$

赞同 221

18 条评论

分享

喜欢

收藏

...

的解

为无穷大，因为可以取  $\alpha_i = \infty, \beta_j h_j(x) = \infty$

- 相反，假设  $x$  满足原始问题的约束条件，则上式最大值一定是  $\alpha = 0$ ，同时  $h(x)=0$ ，所以上式的最大值的条件不存在了，即最大值就是一个定值  $f(x)$
- 所以在  $x$  满足原始问题约束的条件下， $\theta_p(x) = f(x)$

所以，我们可以把原始问题中的 s.t. 条件去掉，得到原始问题的等价问题：

$$\min_x f(x) = \min_x \theta_p(x) = \min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta)$$

如果没看懂，没关系，现在来证明这个等式，即：

$$\min_{x \in R^n} f(x) \quad s.t. \quad c_i(x) \leq 0 (i = 1, 2..k), h_j(x) = 0 (j = 1, 2..l)$$

$\Leftrightarrow$

$$\min_x \max_{\alpha, \beta, \alpha_i \geq 0} (f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)) = \min_x \theta_p(x)$$

- $\max_{\alpha, \beta, \alpha_i \geq 0} (\dots)$ ：在  $x$  是常数的前提下，在取值范围是  $\max$  下标的条件下的，某个  $\alpha, \beta$  使得后面括号中取最大值。
- $\min_x \max_{\alpha, \beta, \alpha_i \geq 0} (\dots)$ ：在上一步对  $x$  取值全部遍历之后，得到的所有的最大值中的一个最小值。
- 将  $\max_{\alpha, \beta, \alpha_i \geq 0} (f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x))$  记做  $P(x)$
- 如果  $x$  满足  $c_i(x) > 0$  或者  $h_j(x) \neq 0$ ，则  $P(x)$  值无限大，则第一步就无解
- 如果  $x$  满足  $c_i(x) \leq 0$  或者  $h_j(x) = 0$ ，又有  $\max$  下标的条件限制，则一定是

$$\sum_{i=1}^k \alpha_i c_i(x) = 0, \quad \sum_{j=1}^l \beta_j h_j(x) = 0, \quad \text{则有:}$$

$$\max_{\alpha, \beta, \alpha_i \geq 0} (f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)) = \max_{\alpha, \beta, \alpha_i \geq 0} (f(x)) = f(x)$$

- 上式两边加  $\min$ ，即证明得等价

综上，我们得到原始问题等价于  $\min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta)$

## 对偶问题

(我可能是好多年没碰高数了，上面一节要啰啰嗦嗦这么多。。)

我们直接给出以下定理：

若原始问题和对偶问题都有最优值，则对偶问题最优值  $d^* \leq$  原始问题最优值  $p^*$ ：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^*$$

(通俗点就是宁做凤尾不做鸡头，凤尾（右）是原始问题，鸡头（左）是对偶问题)

定理1易证明，参考统计学习方法或技法视频，此处证明略。

即我们如果把对偶问题解决了，那就能得到原始问题的下限。

对于对偶问题来说，我们求解最小化部分时没有任何限制条件，而没有限制条件的最小化问题的解一定是在求得 $x$ 的偏导数 $=0$ 这处，那我们就能得到一些等式，将这些等式代入拉格朗日函数中就可以简化计算（svm中可以最终把min消去，且得到一个只与 $\alpha$ 有关的最大化问题）

## KKT条件

推论1：设 $x^*$ 和 $\alpha^*, \beta^*$ 分别是原始问题和对偶问题的可行解，并且 $d^*=p^*$ ，则 $x^*$ 和 $\alpha^*, \beta^*$ 分别是原始问题和对偶问题的最优解。

【即：如果某个解使得最优值相等，则这个解同时是原始和对偶问题的最优解】

定理2：考虑原始问题和对偶问题，假设函数 $f(x)$ 和 $c_i(x)$ 是凸函数， $h_j(x)$ 是仿射函数；并且假设不等式约束 $c_i(x)$ 是严格可行的，即存在 $x$ ，对所有 $i$ 有 $c_i(x) < 0$ ，则存在 $x^*$ 和 $\alpha^*, \beta^*$ ，使 $x^*$ 是原始问题的解， $\alpha^*, \beta^*$ 是对偶问题的解，并且有 $p^*=d^*=L(x^*, \alpha^*, \beta^*)$ 。

【即：满足某些条件下，最优解存在且使得最优值相等】

定理3： $x^*, \alpha^*, \beta^*$  分别是原始问题和对偶问题的解的充分必要条件是， $x^*, \alpha^*, \beta^*$  满足下面的KKT条件：

$$\nabla_x L(x^*, \alpha^*, \beta^*) = 0 \quad \nabla_{\alpha} L(x^*, \alpha^*, \beta^*) = 0 \quad \nabla_{\beta} L(x^*, \alpha^*, \beta^*) = 0 \quad (1) \quad \text{diag}(\alpha_i^*) = 0, i = 1, 2, \dots, h \quad (2) \quad \text{diag}(\alpha_i^*) \leq 0, i = 1, 2, \dots, h \quad (3) \quad \text{diag}(\alpha_i^*) \geq 0, i = 1, 2, \dots, h \quad (4) \quad \text{diag}(\beta_j^*) = 0, j = 1, 2, \dots, l \quad (5)$$

上式条件中1和2是最重要的，3、4、5都是将原始问题表示成拉格朗日函数时的条件。2称为对偶互补条件，根据此条件，当 $\alpha_i^* > 0$ 则 $c_i(x^*) = 0$ 。

【即：在满足KKT条件下，原始问题的求解可以转换成对偶问题来求解，强对偶成立（等号成立），而强对偶成立，又一定满足kkt条件】

两天了，基本理解并写完。

既然都看到这儿了，少年点个赞可好？感谢！

done 2017年11月23日16:51:58

编辑于 2018-02-09

机器学习

## 文章被以下专栏收录



机器学习笔记

ML/AI/DM的经验、心得、笔记

进入专栏

## 推荐阅读

赞同 221

18 条评论

分享

喜欢

收藏

...

primal problem

$$\mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i + b) \geq 1 - \xi_i, i = 1, \dots, N$$
$$\xi_i \geq 0, i = 1, \dots, N$$

Lagrange

$$\min_{\alpha} \frac{1}{2}$$

s. t.

**支持向量机原理详解(二): 拉格朗日对偶函数, SVM的对偶...**

RookieJ

### 【分类战车SVM】第四话: 拉格朗日对偶问题 (原来这么简单...)

第一话: 开篇话第二话: 线性分类  
第三话: 最大间隔分类器第四话: 拉格朗日对偶问题 (原来这么简单!) 第五话: 核函数 (哦, 这太神奇了!) 第六话: SMO算法 (像Smoke一样简单!) 附录: 用...

Ansel...

发表于数说工作室

SVM

- 对偶问题
  - 拉格朗日乘子法
  - 强对偶性
- SVM 优化
  - 软间隔
  - 优化目标及求解
- 解决问题

**【机器学习】支持向量机 SVM (非常详细)**

阿泽

### 18 条评论

[切换为时间排序](#)

写下你的评论...



秋念

2017-12-21

仔仔细细的看了两遍, 终于搞清楚了原始问题和对偶问题以及转换条件, 真的写得非常良心了, 赞~~PS: 前面原始问题的说明一点也不啰嗦, 表示很详细

👍 5



岭大王 (作者) 回复 秋念

2017-12-21

欣慰啊。。。

👍 1



草莓味的工科男

2018-03-07

写的挺好的, 感谢!

👍 赞



行者

2018-04-21

讲的挺棒的, 刚看完《统计学习方法》, 正在疑惑为什么要引入对偶问题来解决原始问题, 搜到这个回答, 醍醐灌顶, 赞一个!

👍 赞



卫星

2018-10-07

写的很棒! 思维很缜密啊。楼主非常厉害了

👍 赞



小白Licko

2019-01-05

master面试ing...

“现在能口头推导出SVM的拉格朗日对偶问题, 就给你申请助学金”  
我为什么没有早点看到这个回答?

👍 赞



知乎用户

2019-02-22

写的好

👍 赞

赞同 221



18 条评论

[分享](#)[喜欢](#)[收藏](#)

5

前来感谢 🙏

👍 赞



冰箱

2019-07-18

谢谢!

👍 赞



流線形

2019-07-24

写的好 清晰易懂

👍 赞



陈夏

2019-09-16

写得很清晰，棒棒棒。

👍 赞



Machinist

2019-10-09

看了这个遍没咋看懂，一会在看一遍

👍 赞



Machinist

2019-10-10

转化为一般问题为啥是那个形式

👍 赞



葱油鸭的脑子

2019-10-20

请教一下：最上面求解条件极值时候用max下的 $\alpha$ ,  $\beta$ ,  $\alpha \geq 0$  的原因是这样就可以将问题条件消除从而得到原始问题吗？因此求解原始问题等价于求解max条件下的min？

此外就是对偶问题中为什么最优解 $\leq$ 原问题最优解？意思是对偶问题的最优解不一定是元问题的最优解，有可能是错误的或者什么的吗？

终于有一篇看进去了！谢谢(\*°▽°)=3

👍 赞



取数表演艺术家 回复 葱油鸭的脑子

03-17

有假设x不满足原始约束时， $P(x)$ 为无穷，当满足原始约束时， $P(x)$ 为 $f(x)$ 。所以原始带有约束问题的最优解，可以转化成无约束问题的最优解。

的确对偶问题的最优解不一定是原问题的最优解。只有强对偶的时候才可以，也就是说满足KKT条件时，等号才成立。

👍 赞



judy

2019-11-04

写的很好，感谢！

👍 赞



东东枪

01-12

感谢

👍 赞



关尔润之

06-08

$\alpha$ 和 $\alpha_i$ 的区别是什么

👍 赞

赞同 221

18 条评论

分享

喜欢

收藏

...